

轮廓系数图

1. 什么是轮廓系数图

轮廓系数图（**Silhouette Plot**）是聚类分析中一种非常重要的可视化工具，用来评估聚类效果的好坏。它基于一个叫做**轮廓系数（Silhouette Coefficient）**的指标，对每个样本的聚类表现进行评分

2. 轮廓系数图的结构


- 横轴：表示轮廓系数的数值范围
- 纵轴：表示聚类中的样本
- 每个样本化成一条横向条形线，长度就是它的轮廓系数值
- **红色虚线**：标记轮廓系数的平均值（所有样本的均值）
- 不同颜色表示不同簇，每个簇是一堆条形的集合

3. 如何解读轮廓图？

- 条形长度越长（接近1）：样本聚类效果好（远离其他簇，靠近自身簇中心）
- 条形长度越短（接近0或负值）：表示这些簇可能存在聚类错误或不稳定性
- 红色虚线是评估聚类整体质量的关键指标，**越高越好**，0.7表示聚类效果非常好，0.5 - 0.7表示聚类结果合理，0.25 - 0.5聚类结果模糊，< 0.25聚类效果可能无意义
- 如果一个簇内大多数样本的轮廓系数都高（接近 1），说明这个簇**轮廓清晰**
- 如果某个簇内部样本轮廓系数**分布很散、甚至有负值**，可能是：
 - 该簇包含了不应该属于它的样本
 - 聚类数设置过多/过少
 - 数据本身不适合强硬分簇
- 如果某一簇中大多数样本轮廓系数为负

- 说明这个簇可能不应该存在，或样本分错簇
- 建议减少聚类数量或尝试其他聚类方法
- 如果簇呈现出轮廓宽度很小、形状扁平
 - 说明该簇中样本数量少，或者样本分布密度低
 - 簇类分的不清晰
 - 簇内样本非常分散
 - 聚类错误

4. 示例解读



- 这张图显示总共有 8 个簇，分别是 0 到 7，颜色不同代表不同的簇。
- 从图中可以看到，大部分簇的样本轮廓值都在 0.4 到 0.8 之间，整体轮廓系数的平均值（红色虚线）大约在 0.58 附近，这说明整体聚类效果是相对较好的。

- 首先观察每一个簇的“形状”与“位置”，簇 5（绿色）样本数量较多，而且大多数轮廓值都在 0.6 左右甚至更高，说明这个簇内部的样本之间非常相似，而且与其他簇的边界也很清晰，是一个比较“理想”的聚类。
- 簇 6（黄色）和簇 3（青色）也表现不错，样本数量中等，轮廓值大多也在平均值附近，表明这两个簇也有一定的紧凑性和良好的边界。
- 再来看一些表现相对不理想的簇。簇 4（绿色细条）和簇 1（紫色）显著窄小，几乎只有一两个样本，轮廓值也偏低。这种簇很可能是一些离群点（outliers）或数据噪声构成的“伪簇”，虽然算法把它们识别为独立的类，但它们实际上可能并不属于任何主要的类别。
- 簇 0（灰色）样本数量最大，但轮廓值分布非常宽，从 0 到接近 0.7。这说明簇 0 内部存在较大的异质性，也就是说，这个簇可能包含了多个“混合”的子簇，有一些样本并不是很适合放在同一个类中。换句话说，簇 0 的定义可能过于宽泛，可以考虑进一步细分。例如你可以尝试增加聚类数，看看能否将簇 0 拆分成更清晰的多个簇，从而提高整体聚类质量。
- 此外，虽然整个图中几乎没有出现明显负值（即左侧没有太多延伸到 0 以下的条形），这说明几乎没有样本明显分错类，这是一个非常积极的信号。负值条形在轮廓图中代表的是“被错误分簇的样本”，你的数据中这类样本非常少，聚类结果具有较高的稳定性和准确性。
- 从整体的角度来看，当前的聚类个数（8个簇）基本是合理的，平均轮廓系数较高，没有严重的错误聚类。
 - 第一，可以考虑移除或合并极小的簇（如簇 1 和 4），因为它们可能是离群点
 - 第二，可以尝试对簇 0 再细化，提高其内部一致性，避免大而松散的簇遮蔽了真实的结构

肘部图 (Elbow Plot)

1. 什么是Elbow plot?

Elbow Method（肘部法） 是一种用于确定 **聚类分析中最优聚类数K** 的启发式方法，特别适用于 **K-Means 聚类算法**。

它的核心思想是：随着聚类数增加，模型的总误差（SSE）会下降，但下降速率在某个点之后会减缓。我们将这个“拐点”称为“肘部”，它通常被认为是最优的


2. 如何解读Elbow Plot?

- 图像一般是一个 **下降曲线**，因为聚类数越多，每个簇更小，误差越小。
- 曲线下降有一个明显的 **拐点 (elbow)**，在这个点之后：
 - 增加聚类数所带来的 **SSE 降低变得有限**
 - 模型复杂度提高但效果提升不显著
 - 换句话说，**边际收益减少**。
- 拐点所对应的 k ，被认为是最合理的聚类数。

3. 优点和局限性

- 优点
 - 简单直观
 - 不依赖先验标签
 - 可用于初步聚类探索
- 局限性
 - Elbow 位置有时不明显，不存在明显“肘部”
 - 对高维数据或复杂分布数据不够准确
 - 仅适用于 **K-Means** 类算法，不适用于 DBSCAN、GMM 等基于密度或概率的聚类。

4. 示例解读



- 这张 Elbow Plot（肘部图）展示了在聚类数 k 从 1 到 15 之间变化时，KMeans 模型的聚类误差（SSE, 或称为惯性）是如何随之变化的。
- 纵轴是 SSE（Sum of Squared Errors），反映了数据点到其对应簇中心的距离平方和，是衡量聚类内部紧密度的常用指标。
- 图中可以看到，当 $k = 1$ 时，SSE 最大，超过 2.7×10^{12} ，此时所有数据点属于一个簇，误差极高
- 随着聚类数增加，SSE 快速下降，这说明更多的簇可以更有效地捕捉样本之间的差异性，使得样本在各自簇中更加紧密。然而，下降趋势在某个点后明显趋于平缓，图中的这个拐点大约出现在 $k = 4$ 附近。
- 从图中观察，聚类数从 $k = 1$ 增加到 $k = 4$ 时，SSE 降低迅速，表明聚类质量大幅提升。而从 $k = 4$ 到 $k = 7$ 虽然仍在下降，但下降幅度明显减缓，之后继续增加聚类数带来的误差降低越来越小。
- 本图中推荐选择 $k = 4$ 或 $k = 5$ 作为初步的聚类数量。这种选择既能保证模型足够区分数据结构，又能避免过度拟合和不必要的复杂性。

聚类结果图

1. 什么是聚类结果图？

聚类结果可视化图通常是一个**二维散点图**，每个点代表一个样本，点的颜色或形状代表它所属的“簇”（cluster）。目的是直观展示聚类算法将数据分成了哪些组，并检视聚类效果。

2. 聚类结果图结构


- 数据点
 - 每个点是一个样本
 - 横轴和纵轴表示选定的两个特征，或者是经过降维（如 PCA 或 t-SNE）后的结果。
 - 这些点按空间分布呈现不同的群体（簇），这些群体在图上通常聚集在一起。
- 颜色
 - 每种颜色代表一个聚类簇（Cluster ID）
 - 颜色越多，聚类的簇数越多。
 - 如果有一类为「-1」或「灰色」，通常代表异常点或未被归类
- 中心点
 - 中心点代表该簇的“质心”或均值位置

3. 如何解读聚类结果图？

- 颜色或标记是否清晰区分
 - 每个颜色或图形标记通常代表一个聚类簇。如果不同簇之间的点有明显边界、分布集中、且类内一致性高、类间分离性强，那么初步说明聚类结果较好。
- 聚类簇的形状、大小是否合理
 - 聚类簇应具有一定的紧凑性（点之间距离较小）
 - 若某个簇比其他簇大很多或分布特别分散，可能表示该簇内部结构不清晰
 - 若某个簇很小，可能是离群点、噪声点或者异常子群体

- 是否存在重叠或边界模糊的簇
 - 如果不同颜色的点在图中重合或重叠较多，可能说明数据在降维后发生扭曲，或原始空间中确实存在边界模糊的样本

4. 示例解读



图的标题是“KMeans Clustering Visualization”，横轴和纵轴分别表示 Component 1 和 Component 2，这是对原始高维数据通过降维（PCA方法）后的两个主成分或嵌入维度，用于在二维空间中可视化不同聚类的分布情况。

每个彩色的点代表一个数据样本，不同颜色代表不同的聚类标签（Cluster Label），图右侧的色条给出了颜色与聚类标签之间的对应关系，从 0 到 7，一共表示该数据被划分为了 8 个簇。此外，图中还用大一点的粉色点标记了每个聚类的“Cluster Centers”，即每个簇的质心位置。

从整体结构上看，该图展示出了一定的聚类效果，但也揭示了聚类中可能存在的一些问题与数据特征。首先，从颜色的分布来看，部分聚类（如标签为0、1、2的类）在图中有比较明显的集中区域，说明 KMeans 成功地将某些相似的数据点归为了同一个类。这种情况出现在图的下方、横轴接近原点的一带，形成了较紧密的聚类结构，颜色边界相对清晰，类内的点彼此靠近。而在其他区域，比如右侧偏远的点如标签为4的类），出现了聚类标签与空间位置分离的现象，部分类别被拉得很远，说明在该数据中存在一些异常值或数值尺度不一致的问题，可能在原始空间中这些点确实更接近聚类中心，但在二维投影后位置偏远。

进一步观察聚类中心的分布，可以发现这些粉色的大点分布在图的各个关键区域，基本覆盖了颜色斑块的重心位置。这表明 KMeans 算法确实计算出了每类样本的几何中心作为簇的代表点。然而值得注意的是，某些簇中心距离其对应颜色点的分布区域较远，表明该类在原始数据空间中可能呈现出较高的离散性或存在多个子群，而不是集中于单一紧凑核心。这种情况往往提示数据内部存在非球状结构，而 KMeans 假设的欧几里得空间等距划分可能不能很好地拟合真实结构，因此聚类效果可能有偏差。

树状图

1. 什么是树状图？

树状图是**层次聚类分析结果的可视化工具**，用于展示样本或变量之间的聚类过程与层级关系。它是一个类似于树的图形结构，其中每一个“叶子节点”代表一个样本，而分支则表示不同样本或聚类之间的**相似度或距离**。

树状图体现了聚类的**递归合并过程**：从每个样本作为一个单独类开始，逐步合并最相似的一对簇，直到最终只剩一个簇。

2. 树状图的结构组成


- 首先，树状图的**底部（叶节点）**表示的是每一个原始样本或特征。这些叶节点通常在图的最下方横向排列，每一个标签对应一个数据点，也就是我们最初的数据输入。

- 接下来是**分支 (Branches)**。这些从底部叶节点开始向上延伸的线条，是树状图的骨架。分支代表样本之间的聚合过程，两个样本或两个聚类在某一阶段的合并会通过一条连线来表示。这些线条逐步将个体样本连接成更大的聚类单元，逐级向上发展。
- **合并点 (节点)** 是指两个分支汇合的地方，它表示两个样本或聚类的合并事件。每一个合并点都是一个新的聚类形成的时刻，越靠上的合并点表示相似性越低，即两个原始样本或聚类之间差异较大才被合并。
- 接下来最关键的是**Y轴 (或树状图的高度)**。Y轴的刻度表示的是“距离”或“不相似度”，也称为**聚类距离 (Linkage Distance)**。它表示两个样本或两个聚类在合并时的距离度量值。这个距离可以根据不同的聚类方法计算，如最小距离 (single linkage)、最大距离 (complete linkage)、平均距离 (average linkage) 或群中心距离 (centroid linkage) 等。Y轴越高的位置表示聚类时差异越大。
- 整个树状图的最顶部，就是**根节点 (Root)**，也就是聚类树的起点。它表示所有样本最终聚合在一起，形成一个整体簇的那一刻。这个根节点之下的分支结构展现了从个体合并到整体的整个聚类过程。
- 此外，有时我们还会在树状图中人为加上一条“**截断线**” (cut-off line)，通常是横向的一条线，表示我们选择在哪一个距离阈值上进行截断，从而决定最终要分多少个簇。所有在截断线以下的合并都算作同一个簇，而在截断线以上的不再合并，形成最终的分组。

3. 如何解读树状图？

- 看“**连线高度**”决定相似性
 - 如果两个样本连接时的高度很低，说明它们**非常相似**；
 - 如果连接高度很高，说明它们相似性较差，仅在较宽松标准下才合并。
- **找出最佳聚类数 (剪枝)**
 - 我们可以**水平剪断树状图** (想象用剪刀横着剪一刀)，剪刀经过的连线数量，就是你要保留的聚类数；
 - 一般剪在**最大垂直距离处的上方**，以获得结构最稳定的聚类划分。
- **识别异常点**
 - **长分支**：若某个数据点或小簇在较高位置才被合并，可能是离群值。例如：一个点直到距离为10才与其他簇合并，说明它与所有簇均不相似。

4. 示例解读



首先，这张热图展示的是多个症状（行）在不同样本或组（列）中的发生强度，以颜色深浅体现频次或强度，红色代表高值，蓝色代表低值，逐步体现出明显的层次结构。通过热图左侧的行聚类 and 顶部的列聚类，可以看出症状或样本之间相似性较强的簇，这有助于识别共现模式和潜在关联。

从行聚类来看，图中将“headache、cough、fatigue、nasal_congestion、muscle_ache 和 sore_throat”分为一大簇。这些症状颜色偏红，说明在大多数样本中，这组症状的出现频率明显高于其它症状，它们可能共同代表了该病症的典型症状群；紧接着略低强度的“itchy_eyes、chest_pain、joint_pain、loss_appetite、nausea_vomiting”组成第二簇，略偏

黄色至淡橙色，表明它们的发生较前者稍低，但与主症状簇仍有相关性。最底部的“loss_smell_taste、temperature、shortness_breath、sputum、chills、diarrhoea”形成另一簇，颜色从绿色到浅蓝色，表明这些症状在样本里出现频率最低，可能代表轻微或少见的次要表现。

列聚类则将样本分为三类或以上：中间几列呈现最深的红色，代表样本中这些核心症状（如头痛、咳嗽、疲劳等）的发生率最高；两侧列则频率递减，左侧列偏冷色，更接近蓝绿色，说明这些样本中大多数症状的活跃度都较低，右侧列则介于中间和左侧之间，表现为中等（黄色至浅橙色）。

结合行列聚类可以得出：中间簇的样本对应一组以核心症状为主的病例群，可能是病症活跃期或症状较重的患者；两侧样本可能包括轻症患者或早期病例，症状表现相对分散且强度较低。行聚类的第一簇核心症状相互关联度强，揭示它们在此次数据集中的共同出现模式；第二簇虽发生强度低一些，但仍可能作为次要症状组合；第三簇则代表罕见或非典型症状，需要进一步关注其在特殊人群或共病状态中的意味。

总体而言，这张热图和层次聚类提供了症状间和样本间的双重关联结构：通过识别高度共现的症状簇，可以帮助临床或流行病学研究聚焦关键症状组合；通过识别样本簇，也可以为分层治疗、症状监测提供参考基础，特别是在筛选高风险患者或制定干预策略时具有实际价值。此外，这样的可视化易于发现潜在的异常样本（如某一系列异常偏蓝或偏红），可进一步用于探索数据质量或分组准确性问题，从而提升下游分析的精准性。

方差比柱状图

1. 什么是方差比？

这个柱状图是用来展示每个主成分所能解释的**原始数据总变异（方差）**的比例。
每根柱子表示一个主成分（PC1、PC2、PC3...），柱子的高度表示该主成了解释了多少比例的方差（也就是信息量）

这种图通常会包含：


- **X轴**：主成分的编号（PC1、PC2、PC3...）
- **Y轴**：每个主成分解释的方差比例
- 有时还会加上一个**累计解释方差曲线（Cumulative Explained Variance）**，以折线的方式展示前N个主成分合起来能解释多少信息。

2. 如何解读方差比柱状图？

- **柱子的高度反映信息量**：越高的柱子表示该主成分越重要，保留了更多的原始信息。比如 PC1 往往最高，它是信息量最大的那个方向。
- **快速下降说明信息集中**：如果从 PC1 到 PC3，柱子高度迅速下降，说明数据大部分的信息集中在前几个主成分中，这种情况适合降维。
- **累计解释方差是判断维度数量的依据**：一般我们会寻找一个“阈值”，比如希望选出能解释 **90% 或 95%** 总方差的最少主成分个数。
 - 如果 PC1-PC3 的累计解释方差已达 90%，那么这三个主成分就能代表原始数据中的大部分信息。
- **是否需要降维？**
 - 如果前几个主成分就能解释大部分方差（比如前5个解释了95%），说明数据存在冗余维度，可以考虑降维。
 - 如果方差分布非常平均（每个主成分贡献差不多），说明维度之间信息量均匀，不宜轻易降维。
- 选择前几个累计解释方差能达到 85%~95% 的主成分作为输入变量，可以有效减少维度、压缩特征冗余。
- 如果前2或3个主成分累计能解释 >80%，则可放心画 2D/3D 可视化图（如 PCA scatter plot），结果有可信度。

####

3. 示例解读



这张图展示的是主成分分析（PCA）中“方差解释比”的柱状图和累积解释比的折线图，是理解高维数据在降维处理后信息保留程度的关键可视化手段。

横轴表示主成分（Principal component），从第1个主成分（PC1）到第18个主成分（PC18）；左侧纵轴为“Individual (%)”，表示每个主成分单独解释的方差比例；右侧纵轴为“Cumulative (%)”，表示从第1个主成分开始，逐步累积到当前主成分所解释的总方差比例。

图中灰色的柱状图代表的是每个主成分单独解释的方差比例。可以看到，第一个主成分解释了接近 33% 的方差信息，是所有主成分中贡献最大的一个；第二个主成分的解释力略低，约为 20%；第三个主成分则为 15% 左右。从第四个主成分开始，单个主成分对方差的解释能力迅速下降，第五、六、七主成分分别在 5% 左右，之后的主成分基本上都小于 3%，越往后下降越明显，接近零。

图中的红色折线和红叉点代表的是累积解释方差比例。我们看到随着主成分数量的增加，累积解释率迅速上升。前两个主成分加起来已经解释了大约 55% 的方差；前三个主成分解释了超过 70%；前五个主成分累计解释了超过 80%；而当主成分数量达到 10 个时，累积解释率接近 95%；最终，在使用全部 18 个主成分后，解释率趋近于 100%。

从这个图来看，一个合适的选择是使用前 3 到 5 个主成分作为分析的基础。前三个主成分可以解释约 70% 的方差，而前五个则已覆盖 80% 以上，说明主要信息已经被高度压缩进这些分量中。进一步使用后续主成分所带来的信息增益变得非常有限，而模型复杂度却在增加。

此外，这张图还可以用于判断原始数据结构是否具有较强的主成分趋势。如果数据的方差分布非常平均，即所有主成分的柱子差不多等高，说明数据本身没有明显的主导方向或结构规律，PCA 对其压缩效果会比较有限。而在本图中，我们看到极明显的首位效应，前两个主成分就解释了大部分方差，这提示数据中存在明显的结构性特征，PCA 能有效地提取出主导信息维度。因此，这类数据适合做 PCA 降维、可视化和特征压缩。

PCA双标图 (PCA Biplot)

1. 什么是PCA Biplot?

- **样本 (Observation)**：每一个点代表一个样本在主成分空间中的位置（通常是 PC1 vs PC2）
- **变量 (Variables)**：用箭头表示原始变量在这个低维空间的投影方向和强度

因此，Biplot 是一个将 **样本分布结构** 和 **变量解释能力** 同时展现出来的图，它通常是解释 PCA 的首选图形工具。


2. Biplot 的结构与组成

- **坐标轴**：PC1 与 PC2
- **散点图**：每个点代表一个样本
 - 样本的坐标是它在 PC1 和 PC2 上的投影
 - 越接近的点表示样本越相似
- **向量箭头**：每个箭头代表一个原始变量
 - 箭头的方向表示变量在主成分空间中的贡献方向
 - 箭头的长度表示变量对这两个主成分的贡献强度（越长贡献越大）
 - 两个箭头夹角越小，说明两个变量越正相关；越接近180°，说明负相关

3. 如何解读Biplot?

- 点的“相对位置”非常关键
 - **靠得近的点**：这些样本在原始变量上的模式很相似。可能属于同一类、或同一聚类簇。
 - **远离中心点的样本**：在主成分方向上有显著的特征差异，往往是“极端样本”或“边缘群体”。
 - **靠近某个箭头的样本**：在那个变量上取值较高，受其强烈影响。
 - 明显的两个或多个聚类，说明主成分有很强的区分力
 - 点的分布方向是否与某些箭头一致？ → 说明这些变量主要主导了数据的变化结构
- 变量层面：箭头的方向与长度
 - **箭头越长**：说明变量在前两个主成分上的解释力越强，越“重要”，表示该变量与 PC1 和 PC2 的线性组合关系越强
 - **箭头越短**：该变量主要在 PC3 以后起作用，或者几乎不参与主成分解释
 - 如果一个箭头指向右上，说明这个变量与 PC1 和 PC2 都有正相关
 - 如果箭头指向 PC1 负方向（左边），它对 PC1 是负向贡献
 - 如果两个箭头夹角很小（接近 0° ），说明这两个变量正相关
 - 如果两个箭头夹角接近 180° ，说明它们负相关
 - 如果箭头几乎正交（接近 90° ），说明两个变量几乎不相关
 - **箭头指向某类样本聚集方向** → 说明该变量对这些样本起了重要作用
- 样本 + 变量联读
 - **关键问题1：哪些样本靠近哪些箭头？**
 - 那些样本很可能在该变量上取值较大
 - 在主成分空间中该变量对这个样本有突出影响。
 - 越靠近，变量越能解释它的特征
 - **关键问题2：哪些变量共同影响了样本的分布？**
 - 哪些箭头集中指向某一方向或样本组 → 它们协同塑造了数据结构

4. 示例解读



这张图是一个典型的 **PCA Biplot**（主成分分析双标图），展示了鸢尾花（Iris）数据集中样本在前两个主成分空间（PC1 与 PC2）中的分布情况，同时也叠加了各变量在该主成分空间中的投影方向。这个图结合了样本分布与变量贡献，是理解高维数据降维后的结构、变量之间关系，以及类别分离能力的一个非常直观的工具。

首先来看散点部分。图中每个点代表一个样本，即一朵鸢尾花，共有三个不同的物种类别：**setosa**（红色）、**versicolor**（绿色）和 **virginica**（蓝色）。这些点根据它们在主成分 PC1 和 PC2 上的得分被投影到二维平面中。PC1 和 PC2 是主成分分析中提取的前两个主成分，分别是原始变量的线性组合，并且是解释原始数据方差最多的两个方向。从图中我们可以看出，**setosa** 类（红色）在 **PC1** 上与其他两类有明显分离，它们集中在左侧，远离其余两个物种。这意味着在原始变量构建出的 PC1 上，setosa 与另外两个物种在形态特征上存在显著差异。而 versicolor 和 virginica 则有一定程度的重叠，说明它们在这两个主成分下的投影不完全可分，但 virginica 更倾向分布在右下方，versicolor 更集中在右上或中间偏右的区域。

接下来关注图中叠加的箭头部分。etal.Length 和 Petal.Width 的箭头几乎指向右上方，表明这两个变量与 PC1 相关性较强，尤其是 Petal.Length，它与 PC1 的方向几乎完全一致，说明该变量在区分样本时是第一主成分的主导因子。

而 Sepal.Width 的箭头则指向左方，表示它与 PC1 负相关，与 PC2 正相关。Sepal.Length 则介于中间，其贡献同时影响 PC1 和 PC2。

箭头之间的夹角也可以用来粗略判断变量之间的相关性。比如 Petal.Length 和 Petal.Width 的箭头几乎共线，表示这两个变量在原始空间中高度正相关。而 Sepal.Width 与 Petal.Length 之间夹角较大，方向几乎相反，说明这两个变量有一定负相关关系。

setosa 类的点主要聚集在左侧，而 Sepal.Width 的箭头也指向左侧，这提示该类样本的花萼宽度更大，而 Petal.Length 和 Petal.Width 指向右方，这说明 setosa 的花瓣较短较窄。

整体来看，这个 Biplot 的效果是相当不错的。它不仅清晰地区分了 setosa 与其他两类样本，也让我们直观了解了各个变量在主成分上的贡献和作用方向。同时，这种可视化方式也揭示了变量之间的相关结构。虽然 versicolor 和 virginica 在这两个主成分下仍有部分重叠，但通过结合箭头方向和样本投影，我们仍然能识别出一些趋势，比如 virginica 往往具有更长更宽的花瓣。若需要进一步区分类别，可以考虑使用更多主成分或者引入监督学习方法。

t-SNE图

1. 什么是t-SNE?

t-SNE (t-Distributed Stochastic Neighbor Embedding) 是一种用于高维数据可视化的非线性降维方法，通常用于将上百维的复杂数据映射到二维或三维空间，以便人类用图形的方式观察数据的结构。

它的设计初衷不是为了做预测，而是为了：

- 探索数据的内在结构
- 发现聚类、分组或潜在的样本关系
- 验证标签是否能在低维空间中分离

2. t-SNE plot 的原理

- 在高维空间中，用高斯核计算样本对之间的相似度（近邻概率）
- 在低维空间中，用 t 分布计算样本对之间的相似度
- 最小化两种相似度分布之间的差异（KL 散度），找到一个低维布局
- t-SNE 不保留全局距离，而是强调 **局部结构（local structure）**，让近邻关系尽量不变。

3. t-SNE图结构组成

一个标准的 t-SNE 图是一个二维散点图：

- 每个点代表一个样本（例如一个人、一张图像、一种细胞类型等）
- 坐标轴是 t-SNE 自动生成的维度（通常是 tSNE1 和 tSNE2，没有实际物理意义）
- 颜色/形状表示标签、分类或其他分组信息

4. 如何解读t-SNE图？

t-SNE 最擅长显示“簇状”结构：

- 如果样本形成了明显的几个团块（cluster），说明这些样本在原始高维空间中具有相似性
- 每一个团块可能代表一个类别、一种细胞类型、一个病人群体等

邻近关系

- **两个点靠得很近** → 原始空间中它们高度相似
- **不同颜色混在一起** → 原始特征区分能力弱，或者类间相似度高

类内连贯性/类间边界


- 看不同类之间是否有清晰边界，边界越清晰，代表原始变量具有更强的分类能力
- 类内如果呈条带、渐变或亚结构，可能说明类内部还存在亚群（subgroup）

全局形状不重要

- 点之间的绝对距离、图的朝向或形状并不重要
- t-SNE 会为了优化局部结构而牺牲全局结构，因此X轴和Y轴的数值没有实际意义

###

5. 示例解读



这张图是一个 **t-SNE** (**t-distributed Stochastic Neighbor Embedding**) 二维可视化图，用来展示细胞类型在高维空间中的分布情况。

在这张图中，我们可以看到多个细胞群体形成了明显的簇，例如“CD4 T cells”、“CD8 T cells”、“B cells”、“NK cells”等。这些簇彼此分离良好，说明各类细胞在原始高维特征空间中也存在相对明显的表达差异或特征分离。

图右上方的蓝色簇表示“NK cells”（自然杀伤细胞），它们在 t-SNE 图中形成一个紧密的聚类，远离其他类型的 T 细胞群体，说明其表达谱具有独特性。

像“CD8 T cells”和“CD4 T cells”这两个簇之间虽然有一定空间距离，但相较于它们与 B cells 或 Megakaryocytes 的距离要更近一些，可能反映了它们在某些生物学特征上的接近性，这与免疫细胞的分类和功能也相符合。

在图的中间位置，有一个非常小的簇被标注为“Dendritic cells”，该簇的样本数量很少，但在空间上明显与其他簇隔离开来。这类小簇往往具有很高的生物学意义，可能代表稀有的细胞类型或具有特殊功能状态的群体

ϵ -邻域距离图 (k-distance plot)

1. 什么是 ϵ -邻域距离图？

k-distance plot 是一种用于帮助选择 DBSCAN 中关键参数 ϵ (epsilon) 的可视化工具。

该图展示了每个样本到其第 k 个最近邻 (k 通常等于 `min_samples`) 的距离，并按照距离从小到大进行排序。其核心思想是：通过可视化所有点的第 k 个最近邻距离的变化趋势，找到一个“转折点”（拐点），作为合适的 ϵ 值。

2. 如何解读这张图？


这张图的关键在于找到那个“转折点” (elbow)：

- 在图的前半段，点密集，k 距离变化不大，说明这些点在局部密度较高的区域，属于同一类簇。
- 在图的后半段，曲线突然变陡，k 距离迅速增大，说明这些点开始落在密度较低的区域，也可能是离群点。

- 拐点的位置所对应的 k -distance 值，就是理想的 ϵ 值。

你可以想象在逐渐增大 ϵ 的过程中，最初只将密集区域的点连接起来，突然在某一值之后，大量低密度点被强行合并，这就是拐点。

3. 示例解读



在 DBSCAN 中， ϵ 和 minPts（最小邻居点数）是两个决定聚类效果的关键超参数。 ϵ 表示某个点要成为“核心点”所需要包含的最小邻域半径，而本图的目的是帮助直观地选择一个合适的 ϵ 值，以便在实际聚类中有效地区分簇与噪声。

图的横轴是“Data Points sorted by distance”，表示所有数据点按距离第 k 个最近邻的距离从小到大排序，而纵轴是“Epsilon”，即这些第 k 近邻距离本身的值。

在图的左下部分，我们可以观察到一个距离相对较小、增长缓慢的区域，这代表大多数密集数据点之间的距离较短，说明它们处于稠密簇中。而随着横轴的增长，曲线出现一个陡然上升的转折点，也就是我们常说的“elbow”或“膝点”。这是因为开始出现稀疏数据点，或者说噪声点，它们与其他点的距离远大于密集区域的点。图中大约在第 200 左右的位置， ϵ 的值开始迅速上升，形成明显拐点，这正是我们确定 DBSCAN 中 ϵ 值的参考依据。根据这个图像，建议将 ϵ 设置在拐点出现之前的一小段范围，也就是 $\epsilon \approx 10$ 到 15 之间最为合适。选择这个范围的 ϵ 可以较好地将数据中的高密度区域聚类，同时把稀疏区域或离群点识别为噪声。