

混淆矩阵 (Confusion matrix)

1. 什么是混淆矩阵?

混淆矩阵(Confusion matrix)是机器学习中用于评估分类模型性能的一种表格布局工具。它以直观的方式展示了模型预测结果与实际情况之间的对应关系，特别适用于二分类问题（但也可扩展到多分类）。

2. 混淆矩阵结构

想象它是一个正方形的格子，行和列的数量取决于分类问题的类别数。对于最简单的二分类问题（比如“是/否”），这个格子就是2行2列共4个数字的方阵。

在二分类问题中，混淆矩阵通常被构建为一个 2×2 的矩阵，横轴表示模型的预测标签，纵轴表示数据的真实标签，其中包含四个基本元素：真正（True Positive, TP）、假正（False Positive, FP）、真负（True Negative, TN）和假负（False Negative, FN）。

在多分类问题中，这个结构会按类别数量扩展。比如三类问题就是 3×3 的格子，对角线上的数字表示各类别被正确分类的数量，其他位置则表示被误分类到其他类别的数量。每一行数字相加就是该类别的实际总样本数，每一列数字相加则是模型预测为该类别的总次数。


3. 如何解读混淆矩阵?

首先要关注对角线元素，这些数字代表模型正确预测的样本数量——对角线上的值越高，说明模型在该类别上的准确性越好。例如，在二分类问题中，左上角的真正例（TP）表示模型正确识别出的正类样本，右下角的真负例（TN）表示正确识别的负类样本，这两个数值越大，模型的整体表现越好。

然而，仅仅看对角线是不够的，我们还需要分析**非对角线元素**，因为它们揭示了模型的错误模式。例如，**假正例（*FP）表示模型将负类误判为正类的数量**，而假负例（FN）表示模型漏判的正类样本。如果FP较高，说明模型存在过度预测正类的倾向；如果FN较高，则可能意味着模型过于保守，漏掉了许多实际的正类样本。

在多分类问题中，混淆矩阵的解读更加细致。我们可以观察哪些类别容易被混淆，比如类别A的样本是否经常被误判为类别B，这可能意味着这两个类别在特征上较为相似，需要进一步优化模型或调整特征工程。

4. 示例解读



总共有 4 个类别，编号为 0，1，2，3 。

横轴是模型的 **预测结果** (Predicted)

纵轴是 **真实标签** (Actual)

从图中可以看出，矩阵的纵轴表示真实类别 (Actual) ， 横轴表示模型的预测结果 (Predicted) ， 颜色越深代表样本数量越多。分析从每一个实际类别的预测表现出发。

- 先看类别0，这是样本数最多的一类，共有272个样本，其中有252个被正确分类，占比达到92.3%。这说明模型在识别类别0方面表现非常出色，仅有极少数（17个被误判为类别1，2个为类别2，1个为类别3）被错分。
- 类别1的表现中等，总共75个样本中仅有40个被正确分类，占比53.3%，其余被误分类为类别0（25个）、类别2（9个）和类别3（1个），表明模型在类别1与其他类别的边界上可能存在一定模糊。

- 更严重的问题出现在类别2，共有28个样本，仅有4个被正确识别，准确率仅为11.8%，大部分被错误分类为类别1（16个）和类别0（5个），这说明模型几乎无法有效区分类别2，可能由于类别特征不明显、样本过少或数据本身存在噪声。
- 类别3共有24个样本，其中12个被正确预测，准确率为48%，其余被错误分配为类别0（1个）、类别1（4个）和类别2（7个），说明模型对类别3的识别能力也较为有限。

从整体表现来看，该模型在面对类别分布不均的数据时，展现出了明显的偏向性。尤其是对类别0的偏好预测表明该类别在训练集中的占比可能远高于其他类别，导致模型在优化过程中倾向于最大化该类的准确率，牺牲了对其他类别的识别能力。

- 类别1与类别3的准确率略高于随机水平，可能仍有一定的识别依据，但表现依然不能令人满意。特别是类别2的预测几乎完全失败，值得引起重视。

为了改进该模型的表现，可以考虑从以下几个方向着手：

- 处理类别不平衡问题，比如通过过采样（SMOTE）、欠采样或类别加权等方式，增强少数类的学习权重；
- 加强特征工程，对表现差的类别进一步探索其特征分布，判断是否存在显著重叠或缺乏判别力的维度，必要时可以尝试降维或构造新特征
- 在模型选择方面，可以使用更强的集成学习模型（如XGBoost、LightGBM或CatBoost）或采用深度学习模型进行更复杂的特征拟合；

ROC curve, AUC

1. 什么是ROC和AUC?

ROC AUC 曲线（Receiver Operating Characteristic - Area Under the Curve）是机器学习中用来评估二分类模型性能的经典工具，尤其适用于样本类别不平衡的情况。ROC 曲线的本质是在不同的分类阈值下，衡量模型对正负样本的区分能力，它通过绘制真正率（True Positive Rate, TPR）与假正率（False Positive Rate, FPR）之间的关系来构造曲线，从而反映模型整体预测性能。TPR，也称为召回率（Recall），表示所有实际为正类的样本中被模型成功识别出来的比例；而 FPR 则是所有实际为负类的样本中被误判为正类的比例。

ROC曲线绘制时，将FPR作为横轴，TPR作为纵轴。在分类模型中，往往会有一个概率输出或者得分（score），比如逻辑回归输出预测为正类的概率。通过调整这个概率的阈值（threshold），我们可以得到不同的分类结果。阈值越低，判定为正类的样本越多，TPR和FPR都可能上升；阈值越高，模型越严格，判定为正类的样本减少，TPR和FPR都可能降低。

而 AUC（Area Under the Curve）正是该 ROC 曲线下的面积，数值范围在0到1之间。


2. 如何解读？

理想情况下，一个完美分类器能在低 FPR 时达到高 TPR，ROC 曲线将靠近左上角，形成一条接近垂直后水平的曲线。而一个随机猜测的分类器，其 TPR 和 FPR 随阈值变化近似等比增长，ROC 曲线近似一条对角线（ $TPR = FPR$ ），这代表模型没有学习到有用的信息。

AUC 值越接近1，说明模型越接近完美分类；AUC 为0.5表示模型没有区分能力，与随机分类相同；而 AUC 小于0.5 说明模型在预测正负类别时反向学习，甚至可以通过将预测反转来提高性能。AUC 有一个直观的解释：它等价于随机选取一个正类样本和一个负类样本，模型将正类排在负类之前的概率。这种概率意义非常直观，尤其在存在样本不平衡或阈值不固定时，AUC 提供了比 Accuracy 更稳健的评估标准。

使用 ROC AUC 有几点需要注意。首先，它只关注排序，不考虑实际概率值的绝对准确性。因此一个概率预测模型即使分数偏离真实概率很远，只要排序正确，AUC 仍然可能很高。其次，在极度类别不平衡的情况下，虽然 AUC 能保持稳定，但实际业务可能更关心特定召回率下的精确率（Precision），此时 PR 曲线和 PR-AUC 更合适。此外，ROC 曲线适用于二分类任务，对于多分类任务，通常通过 One-vs-Rest（OvR）策略将问题转化为多个二分类子问题，分别计算每一类的 ROC AUC，最后求平均（宏平均或加权平均）得到总体指标。

3. 示例解读



这张图展示的是一个多模型比较的受试者工作特征曲线（ROC Curve），用于评估不同特征组合在乳腺癌检测中的分类性能

条曲线代表一个模型的表现：黑色实线表示结合甲基化和基因表达（Methyl+Exp）的模型，蓝色虚线表示仅使用甲基化特征（Methylation）的模型，红色虚线则代表仅使用基因表达特征（Expression）的模型。图中右下角列出了三条曲线对应的AUC值（曲线下面积），分别为0.947、0.897 和 0.846，代表三种模型的整体分类能力。

- 从图中可以明显看出，三条曲线均远离随机分类线（灰色对角线， $AUC = 0.5$ ），表明所有模型都具有显著的预测能力。
- 黑色实线的Methyl+Exp模型在整个曲线范围内表现最优，其AUC高达0.947，说明该模型在所有分类阈值下都能保持较高的敏感性和特异性，几乎接近完美分类。
- 蓝色的甲基化模型次之，AUC为0.897，也表现出色，但相比黑色曲线略有下降。红色的基因表达模型AUC为0.846，虽然仍具备较强的判别力，但性能明显低于其他两种模型。

- 从曲线形态来看，黑色曲线在低假阳性率（ $1 - \text{Specificity}$ 接近0）时的敏感性明显高于其他曲线，意味着在保持极低误报率的前提下仍能准确识别出大多数真实病例（高灵敏度）。蓝色曲线虽然整体优于红色，但在中段（假阳性率0.2~0.4区间）表现波动，显示模型在部分阈值下可能不够稳定

结论与建议：

1. **联合特征策略优越**：Methyl+Exp模型明显优于任一单独特征来源，表明融合甲基化和表达数据可有效捕捉肿瘤发生机制的不同维度，从而提升诊断准确性。建议在实际模型构建中优先考虑多组学数据融合。
2. **甲基化优于表达**：虽然两者都可作为乳腺癌的生物标志物，但本图显示甲基化信息提供的判别力更强（AUC 0.897 vs 0.846）。这或许反映出DNA甲基化更早发生于肿瘤发生过程，更具预警能力。对于资源受限的临床场景，优先考虑甲基化检测可能更具性价比。

PR Curve

1. 什么是PR curve?

在二分类机器学习任务中，尤其是面对类别不平衡的问题时，Precision-Recall (PR) 曲线成为比传统 ROC 曲线更具解释力和实用价值的评估工具。PR 曲线是以召回率 (Recall, 灵敏度) 为横轴，精确率 (Precision) 为纵轴所绘制的二维曲线，用以衡量分类器在不同阈值下对正类样本的识别能力。当我们对一个样本的预测输出是一个概率值（如逻辑回归或神经网络的 sigmoid 输出），可以通过不断改变分类阈值，得到一系列的 (Recall, Precision) 点，进而构成完整的 PR 曲线。

- **Precision (精确率)** 衡量的是模型所有预测为正类的样本中，有多少是真正的正类
- **Recall (召回率)** 衡量的是所有真实正类样本中，有多少被模型成功识别出来


与传统的ROC曲线不同，PR曲线聚焦于正类的预测质量，而非全局分类性能，因此当我们处理如疾病筛查、罕见事件识别等正类比例极低的任务时，PR曲线提供了更敏感、更具现实意义的评估方式。

2. 如何解读?

解读一条PR曲线时，我们首先观察其整体形状。如果模型表现优秀，PR曲线应当整体位于图像的右上角，意味着在高召回率的同时仍能维持较高的精确率。这是一个非常理想但现实中难以实现的状态，因为在实践中，Precision 和 Recall 往往存在权衡关系。当我们调整模型的分类阈值以捕捉更多正类（提高 Recall）时，往往也会增加误识别的负类样本数量，导致 Precision 下降；相反，当我们提高分类置信度要求（提高 Precision），则可能漏掉许多真正的正类，导致 Recall 降低。因此，PR曲线一般从左上角开始，随着召回率逐步上升，精确率呈下降趋势，最终趋于模型的最差状态或正类比例的基准线

PR曲线对正类样本的比例非常敏感。如果正类极少，那么即使错误预测少量负类为正类，也会导致 Precision 急剧下降；这正是PR曲线能在类别不平衡中凸显模型性能差异的原因。当解读一张PR曲线时，我们常会关注其“面积”，即平均精确率（Average Precision, AP），它代表了PR曲线下的整体面积，越大表示模型综合性能越好。一个完美的分类器的PR曲线将是一条位于图像顶端的水平线，其AP为1，而一个随机猜测的分类器的精确率将趋于正类的基线比例，AP会较低。

3. 示例解读



这张精确率-召回率(PR)曲线图展示了机器学习模型在预测不同阶段痴呆症方面的性能表现，为我们提供了关于模型诊断准确性的深入洞察。与ROC曲线不同，PR曲线特别适用于不平衡数据集的分析，而在痴呆症诊断中，健康人群远多于患者的情况正是不平衡数据集的典型场景。图中展示了五个不同痴呆阶段的PR曲线及其对应的AUC值：前驱期(PRC)为0.91，轻度认知障碍(MCI)为0.93，轻度痴呆为0.88，中度痴呆为0.88，以及重度痴呆为0.95。这些AUC值整体处于较高水平，表明模型在各类痴呆分期诊断中均表现出色，其中对重度痴呆的识别能力最为精准(AUC=0.95)，而对轻度痴呆和中度痴呆的识别相对稍弱，但仍保持在较高水平(AUC=0.88)。

理想情况下，完美的PR曲线应该从左上角(精确率=1.0，召回率=1.0)开始，保持高水平向右延伸。本模型在低召回率区域(0.0-0.4)表现出极高的精确率，这意味着当模型以较高阈值判定阳性病例时，其判断极为可靠，几乎不会产生误诊。随着召回率提高至0.6-0.8范围，精确率开始出现不同程度的下滑，这种变化模式符合预期，因为提高疾病检出率(召回率)通常需要以接受更多假阳性病例(降低精确率)为代价。特别值得注意的是，在召回率达到0.8以上时，重度痴呆的精确率下降幅度明显小于其他阶段，这反映了模型对晚期痴呆症状的特征捕捉更为准确。

从临床应用角度考量，这些PR曲线的分析结果具有重要的实践意义。在痴呆症的早期筛查场景中，我们可以选择高召回率的工作点(如0.8-1.0)以确保尽可能多地识别潜在病例，尽管这会带来相对较多的假阳性，但后续可以通过更详细的临床评估排除这些病例。而在确诊或治疗监测场景中，则可能选择中等召回率(0.6左右)的工作点，以平衡精确率和召回率，减少不必要的进一步检查。模型对重度痴呆的优异识别能力(AUC=0.95)特别适合用于护理机构中的患者监测，可以及时识别病情恶化的个体并调整护理方案。相比之下，对轻度痴呆和中度痴呆相对稍弱的区分能力(AUC=0.88)提示我们在临床应用中需要结合其他评估工具来确认这些阶段的诊断。